

Qwen3-7B、Xiaomi-7B、GLM-4V-Flash 和 DeepSeek-8B 模型评测分析报告

1. 引言

本报告基于 BeNEDect 数据集（9600 条样本），对 Qwen3-7B、Xiaomi-7B、GLM-4V-Flash 和 DeepSeek-8B 模型的数值错误检测性能进行分析。任务为判断段落中的数字是否错误（Yes/No），评测指标包括准确率（Accuracy）、真阳性（TP）、真阴性（TN）、假阳性（FP）、假阴性（FN）和生成错误（Generation Error）。报告从总体性能、按领域、错误类型、操作和提示类型五个维度对比模型表现，分析优劣势，并提出优化建议。

2. 总体性能分析

2.1 总体指标

指标	Qwen3-7B	Xiaomi-7B	GLM-4V-Flash	DeepSeek-8B
准确率 (Accuracy)	0.479	0.472	0.594	0.463
真阳性 (TP)	4443 (0.463)	4347 (0.453)	3353 (0.349)	3849 (0.401)
真阴性 (TN)	156 (0.016)	181 (0.019)	2350 (0.245)	593 (0.062)
假阳性 (FP)	4644 (0.484)	4619 (0.481)	2450 (0.255)	4207 (0.438)
假阴性 (FN)	357 (0.037)	453 (0.047)	1447 (0.151)	951 (0.099)
生成错误 (Generation Error)	577 (0.060)	634 (0.066)	2 (0.000)	509 (0.053)

分析：

- 准确率**：GLM-4V-Flash (0.594) 显著优于其他模型，Qwen3-7B (0.479)、Xiaomi-7B (0.472) 和 DeepSeek-8B (0.463) 表现接近，但均低于 0.5，表明整体性能有待提升。
- 真阳性 (TP)**：Qwen3-7B (4443) 和 Xiaomi-7B (4347) 在识别错误数字方面优于 GLM-4V-Flash (3353) 和 DeepSeek-8B (3849)，但 GLM-4V-Flash 的低 TP 可能因其更严格的预测策略。
- 真阴性 (TN)**：GLM-4V-Flash (2350, 0.245) 远超其他模型，表明其在识别非错误数字方面表现最佳；DeepSeek-8B (593) 次之，Qwen3-7B (156) 和 Xiaomi-7B (181) TN 比例极低 (<0.02)。
- 假阳性 (FP)**：Qwen3-7B (0.484) 和 Xiaomi-7B (0.481) FP 比例最高，表明模型易将正确数字误判为错误；GLM-4V-Flash (0.255) FP 最低，预测更保守。
- 假阴性 (FN)**：Qwen3-7B (357) FN 最低，Xiaomi-7B (453) 和 DeepSeek-8B (951) 次之，GLM-4V-Flash (1447) FN 较高，可能因其对错误数字的敏感度不足。
- 生成错误**：GLM-4V-Flash (2, 0.000) 生成错误极低，展现极高的生成稳定性；DeepSeek-8B (509, 0.053) 优于 Qwen3-7B (577, 0.060) 和 Xiaomi-7B (634, 0.066)。

结论：GLM-4V-Flash 在准确率、TN 和生成错误率方面表现最佳，适合需要高稳定性和低误判的场景。Qwen3-7B 和 Xiaomi-7B 在 TP 方面较强，但高 FP 和低 TN 限制了性能。DeepSeek-8B 表现均衡，但 FN 较高。

3. 按领域（Domain）性能分析

3.1 领域指标

领域	Qwen3-7B Accuracy	Xiaomi-7B Accuracy	GLM-4V-Flash Accuracy	DeepSeek-8B Accuracy	Qwen3-7B Gen. Error	Xiaomi-7B Gen. Error	GLM-4V-Flash Gen. Error	DeepSeek-8B Gen. Error
Numeracy_600K_article_title	0.510	0.508	0.615	0.482	0 (0.000)	1 (0.001)	0 (0.000)	0 (0.000)
aclsent	0.509	0.497	0.606	0.474	0 (0.000)	8 (0.004)	0 (0.000)	0 (0.000)
DROP	0.364	0.387	0.494	0.280	569 (0.227)	550 (0.219)	0 (0.000)	499 (0.200)
qa-text-source-comparison	0.485	0.463	0.564	0.468	8 (0.004)	35 (0.018)	2 (0.001)	8 (0.004)
FinNum	0.497	0.468	0.514	0.467	0 (0.000)	40 (0.020)	0 (0.000)	2 (0.001)

分析：

- Numeracy_600K_article_title：**GLM-4V-Flash (0.615) 准确率最高，生成错误为 0；Qwen3-7B (0.510) 和 Xiaomi-7B (0.508) 接近，DeepSeek-8B (0.482) 最低。
- aclsent：**GLM-4V-Flash (0.606) 领先，Qwen3-7B (0.509) 和 Xiaomi-7B (0.497) 次之，DeepSeek-8B (0.474) 较弱。
- DROP：**GLM-4V-Flash (0.494) 表现最佳，且生成错误为 0；Qwen3-7B (0.364)、Xiaomi-7B (0.387) 和 DeepSeek-8B (0.280) 准确率低，生成错误高（20%-23%），表明 DROP 数据集的复杂性（如长文本或数字关系）是主要挑战。
- qa-text-source-comparison：**GLM-4V-Flash (0.564) 领先，DeepSeek-8B (0.468) 和 Qwen3-7B (0.485) 接近，Xiaomi-7B (0.463) 生成错误较高（35）。
- FinNum：**GLM-4V-Flash (0.514) 最佳，Qwen3-7B (0.497) 次之，Xiaomi-7B (0.468) 和 DeepSeek-8B (0.467) 接近。

结论：GLM-4V-Flash 在所有领域表现最佳，尤其在 DROP 数据集上展现高稳定性和准确性。DROP 是其他模型的性能瓶颈，需针对其高生成错误优化推理逻辑。

4. 按错误类型（Error Type）性能分析

4.1 错误类型指标

错误类型	GLM-4V-Flash TP	Qwen3-7B TP	Xiaomi-7B TP	DeepSeek-8B TP	GLM-4V-Flash TN	Qwen3-7B TN	Xiaomi-7B TN	DeepSeek-8B TN	GLM-4V-Flash Gen. Error	Qwen3-7B Gen. Error	Xiaomi-7B Gen. Error	DeepSeek-8B Gen. Error
Error in Number Relationships	149	192	187	161	79	3	6	24	0 (0.000)	6 (0.015)	7 (0.018)	4 (0.010)
Undetectable Error	278	445	446	387	217	11	7	69	0 (0.000)	18 (0.018)	24 (0.024)	14 (0.014)
Type Error	389	508	495	415	252	19	16	82	2 (0.002)	16 (0.013)	23 (0.019)	10 (0.008)
Anomaly	173	219	214	186	107	7	14	27	0 (0.000)	14 (0.029)	15 (0.031)	10 (0.021)
Improper Data	18	29	28	27	11	1	0	3	0 (0.000)	0 (0.000)	0 (0.000)	0 (0.000)
Factual Error	43	55	52	45	30	2	8	5	0 (0.000)	2 (0.016)	3 (0.024)	2 (0.016)

分析：

- Error in Number Relationships:** GLM-4V-Flash TN (79) 远超其他模型，表明其在非错误数字识别上更强；Qwen3-7B (192) 和 Xiaomi-7B (187) TP 较高，DeepSeek-8B (161) 稍弱。
- Undetectable Error:** Qwen3-7B 和 Xiaomi-7B TP 最高 (约 445)，但 TN 低 (<11)；GLM-4V-Flash TN (217) 最佳，DeepSeek-8B (69) 次之。
- Type Error:** Qwen3-7B (508) TP 最高，GLM-4V-Flash (389) TN (252) 领先，DeepSeek-8B 生成错误最低 (10)。
- Anomaly:** GLM-4V-Flash TN (107) 最佳，Qwen3-7B (219) TP 最高，Xiaomi-7B 和 DeepSeek-8B 接近。
- Improper Data 和 Factual Error:** 样本量少，GLM-4V-Flash TN 最高，生成错误极低。

结论：GLM-4V-Flash 在 TN 方面全面领先，适合高可靠性场景；Qwen3-7B 和 Xiaomi-7B 在 TP 上更强，但 TN 低；DeepSeek-8B 表现均衡，生成错误较低。

5. 按提示类型 (Prompt Type) 性能分析

5.1 提示类型指标

提示类型	Qwen3-7B Accuracy	Xiaomi-7B Accuracy	GLM-4V-Flash Accuracy	DeepSeek-8B Accuracy	Qwen3-7B Gen. Error	Xiaomi-7B Gen. Error	GLM-4V-Flash Gen. Error	DeepSeek-8B Gen. Error
few_shot	0.595	0.404	0.582	0.548	18 (0.072)	28 (0.112)	0 (0.000)	12 (0.048)
zero_shot	0.476	0.475	0.594	0.462	559 (0.060)	606 (0.065)	2 (0.000)	497 (0.053)

分析：

- few_shot:** Qwen3-7B (0.595) 准确率最高，GLM-4V-Flash (0.582) 和 DeepSeek-8B (0.548) 次之，Xiaomi-7B (0.404) 最低。GLM-4V-Flash 生成错误为 0，DeepSeek-8B (12) 最低，Xiaomi-7B (28) 较高。
- zero_shot:** GLM-4V-Flash (0.594) 领先，Qwen3-7B (0.476)、Xiaomi-7B (0.475) 和 DeepSeek-8B (0.462) 接近。GLM-4V-Flash 生成错误极低 (2)，其他模型生成错误比例较高 (5%-6%)。
- 生成错误:** few_shot 模式下生成错误比例高于 zero_shot，可能因提示复杂度增加。

结论：GLM-4V-Flash 在两种提示类型下均展现高稳定性和准确率；Qwen3-7B 在 few_shot 模式下表现突出；DeepSeek-8B 在 few_shot 中优于 Xiaomi-7B，但 zero_shot 性能一般。

6. 结论

GLM-4V-Flash 在准确率 (0.594)、TN (0.245) 和生成错误率 (0.000) 方面显著优于 Qwen3-7B (0.479)、Xiaomi-7B (0.472) 和 DeepSeek-8B (0.463)，尤其在 DROP 数据集和复杂操作中展现高稳定性。Qwen3-7B 在 few_shot 模式和 TP 方面表现突出，DeepSeek-8B 性能均衡但 FN 较高，Xiaomi-7B 生成错误率最高。所有模型受高 FP、低 TN 和 DROP 数据集的高生成错误限制。建议优化解析规则、提示设计和推理流程，补充 JSON 数据，并针对 DROP 数据集进行微调。未来可引入更大规模模型 (如 Llama 3.1-70B) 进一步提升性能。

